

Wolfe线搜索下一个新的共轭梯度法及其在信号处理中的应用

刘莹^{1,2,3}, 朱志斌^{1,2,3}, 丁玥宏^{1,2,3}, 黄嘉琪^{1,2,3}

(1. 桂林电子科技大学数学与计算科学学院, 广西 桂林 541004; 2. 广西高校数据分析与计算重点实验室, 广西 桂林 541004; 3. 桂林电子科技大学广西应用数学中心, 广西 桂林 541004)

摘要: 本文考虑无约束优化问题, 提出了一个新的共轭梯度方法, 命名为NYHS共轭梯度法. 并且证明了在标准Wolfe线搜索下, NYHS方法具有下降性和全局收敛性. 将本文提出的算法应用于信号处理中的图像恢复问题和正则化逻辑回归模型, 结果表明本文提出的方法是有效的.

关键词: 无约束优化; 共轭梯度法; 全局收敛; 图像恢复; 正则化逻辑回归

中图分类号: O221.2

AMS(2010)主题分类: 90C30; 65K10

文献标识码: A

文章编号: 1001-9847(2025)01-0104-10

DOI:10.13642/j.cnki.42-1184/o1.2025.01.004

1. 引言

考虑如下无约束优化问题:

$$\min\{f(x)|x \in \mathbb{R}^n\}, \quad (1.1)$$

其中: $f(x): \mathbb{R}^n \rightarrow \mathbb{R}$, 是连续可微函数, 梯度记为 $g(x): \mathbb{R}^n \rightarrow \mathbb{R}^n$.

共轭梯度法是求解上述无约束优化问题(1.1)的一种重要方法, 其一般的迭代公式为:

$$x_{k+1} = x_k + \alpha_k d_k, \quad (1.2)$$

$$d_k = \begin{cases} -g_k, & k = 1, \\ -g_k + \beta_k d_{k-1}, & k > 1, \end{cases} \quad (1.3)$$

其中, d_k 为搜索方向, β_k 为共轭参数, α_k 为通过沿 d_k 为搜索方向的某种线搜索获得的步长, g_k 为当前迭代点 x_k 处的梯度.

共轭梯度法在求解线性方程组和优化问题时具有较快的收敛速度, 较小的内存占用, 适应稀疏矩阵, 可并行化以及较好的数值稳定性等优点, 吸引了国内外众多学者对其进行深入的研究. 不同的参数对应不同的共轭梯度法, 著名的 β 公式有: Dai-Yuan(DY)^[1], Fletcher-Reeves(FR)^[2], Polak-Ribière-Polyak(PRP)^[3-4], Hestenes-Stiefel(HS)^[5], 它们的具体形式如下:

$$\beta_k^{\text{DY}} = \frac{\|g_k\|^2}{d_{k-1}^T y_{k-1}}, \quad \beta_k^{\text{FR}} = \frac{\|g_k\|^2}{\|g_{k-1}\|^2}, \quad \beta_k^{\text{PRP}} = \frac{g_k^T y_{k-1}}{\|g_{k-1}\|^2}, \quad \beta_k^{\text{HS}} = \frac{g_k^T y_{k-1}}{d_{k-1}^T y_{k-1}}$$

* 收稿日期: 2023-11-11

基金项目: 国家自然科学基金 (61967004, 11901137); 广西密码学与信息安全重点实验室研究课题 (GCIS201927); 广西自动检测技术与仪器重点实验室项目 (YQ20113); 广西研究生教育创新项目 (2021Y-CXS118); GUET研究生教育创新项目 (2023YCXS113)

作者简介: 刘莹, 女, 汉族, 山西人, 研究方向: 优化理论及其应用.

其中 $\|\cdot\|$ 为欧氏范数, $y_{k-1} = g_k - g_{k-1}$.

这几种原始的共轭梯度法虽然在收敛性质与数值实验上各具特点, 但对于目标函数是二次函数且采用精确线搜索时, 这几种方法等价. 为了寻求既保证收敛性又有良好数值表现的共轭梯度方法, 很多学者在以上公式的基础上提出了改进的共轭梯度算法. 如文[6]提出的EHS-RD1和EHS-RD2方法, 在弱Wolfe线搜索下满足全局收敛性, 文[7]提出的RMIL CGM的混合变体, 文[8]中提出的改进的PRP共轭梯度方法.

文[9]提出了一种共轭梯度法, 其 β_k 的公式为:

$$\beta_k^{\text{WYL}} = \frac{g_k^T (g_k - \frac{\|g_k\|}{\|g_{k-1}\|} g_{k-1})}{\|g_{k-1}\|^2}, \quad (1.4)$$

在Wolfe线搜索下是全局收敛的.

文[10]将WYL共轭梯度法与其它共轭梯度方法进行组合, 其 β_k 公式为:

$$\beta_k^{\text{MJ}} = \begin{cases} \frac{g_k^T (g_k - \frac{\|g_k\|}{\|d_{k-1}\|} d_{k-1})}{d_{k-1}^T y_{k-1}}, & g_k^T d_{k-1} > 0 \\ \frac{g_k^T (g_k + \frac{\|g_k\|}{\|d_{k-1}\|} d_{k-1})}{d_{k-1}^T y_{k-1}}, & g_k^T d_{k-1} \leq 0 \end{cases}, \quad (1.5)$$

在Wolfe线搜索下, 具有全局收敛性.

文[11]提出了一种新型充分下降的共轭梯度法, 其 β_k 公式为:

$$\beta_k^{\text{SDCG}} = \frac{\|g_k\|^2}{\mu(\|d_{k-1}\|^2 + \|g_k\|^2)}, \mu > \frac{1}{2}, \quad (1.6)$$

在弱Wolfe线搜索下满足全局收敛性.

文[12]在很多FR共轭梯度法的变体上提出了一种新的共轭梯度法, 其 β_k 公式为:

$$\beta_k^{\text{DPRP}} = \frac{\|g_k\|^2 - \frac{\|g_k\|}{\|g_{k-1}\|} |g_k^T g_{k-1}|}{\mu |g_k^T d_{k-1}| + \|g_{k-1}\|^2}, \mu > 1, \quad (1.7)$$

在Wolfe线搜索或者Armijo线搜索下全局收敛.

在文[9-12]的启发下, 本文提出了新的共轭参数:

$$\beta_k^{\text{NYHS}} = \frac{g_k^T g_k + \frac{\|g_k\|}{\|g_{k-1}\|} g_k^T g_{k-1}}{(1 + 2\|g_k\|)\|d_{k-1}\|}. \quad (1.8)$$

本文余下内容结构如下: 第2节给出NYHS共轭梯度算法, 验证其搜索方向满足下降条件. 第3节证明该方法的全局收敛性. 第4节为NYHS算法在信号处理中的应用. 首先针对图像恢复问题进行数值实验, 验证本文方法的有效性, 其次针对正则化逻辑回归模型进行数值实验, 验证本文方法的有效性. 第5节给出本文的结论.

2. NYHS共轭梯度法的下降性

本文采用标准Wolfe线搜索:

$$f(x_k + \alpha_k d_k) - f(x_k) \leq \rho \alpha_k g_k^T d_k, \quad (2.1)$$

$$g(x_k + \alpha_k d_k)^T d_k \geq \sigma g_k^T d_k, \quad (2.2)$$

其中 $0 < \rho < \sigma < 1$.

在本文, 基于(1.8), (2.1), (2.2)式, 提出一种共轭梯度法, 称为NYHS共轭梯度法.

算法2.1(NYHS共轭梯度算法)

步1 初始值 $x_0 \in \mathbb{R}^n$, $\rho \in (0, 1)$, $\sigma \in (\rho, 1)$, $\epsilon > 0$, $d_1 = -g_1$, 令 $k = 1$.

步2 若 $\|g_k\| \leq \epsilon$, 停止.

步3 由(1.8)式计算 β_k , 由(1.3)式计算 d_k .

步4 计算步长 α_k 满足标准Wolfe线搜索(2.1), (2.2)式.

步5 置 $x_{k+1}=x_k+\alpha_k d_k$.

步6 置 $k=k+1$, 转步2.

定理2.1 考虑NYHS算法. 序列 $\{g_k\}$, $\{d_k\}$ 由该算法生成, β_k 由(1.8)式产生, α_k 满足标准Wolfe线搜索(2.1), (2.2)式, 则 $\forall k \geq 1$, 有

$$g_k^T d_k \leq 0. \quad (2.3)$$

证 1) 当 $k=1$ 时, $d_1 = -g_1$, 有 $g_1^T d_1 = -g_1^T g_1 = -\|g_1\|^2 < 0$, 结论成立.

2) 当 $k > 1$ 时, $d_k = -g_k + \beta_k d_{k-1}$, 有

$$\begin{aligned} g_k^T d_k &= -\|g_k\|^2 + \frac{g_k^T g_k + \frac{\|g_k\|}{\|g_{k-1}\|} g_k^T g_{k-1}}{(1 + 2\|g_k\|)\|d_{k-1}\|} g_k^T d_{k-1} \leq -\|g_k\|^2 + \frac{\|g_k\|^3 + \|g_k\|^3}{1 + 2\|g_k\|} \\ &= -\|g_k\|^2 + \|g_k\|^2 \frac{2\|g_k\|}{1 + 2\|g_k\|} = -\frac{\|g_k\|^2}{1 + 2\|g_k\|} < 0. \end{aligned}$$

综上, 结论成立, 证毕.

3. 收敛性分析

为了确保NYHS共轭梯度法的全局收敛性, 下面给出所需要的两个常规假定:

(H1) $f(x)$ 在水平集 $\Omega = \{x \in \mathbb{R}^n | f(x) \leq f(x_1)\}$ 上有下界, 其中 x_1 为初始点.

(H2) $f(x)$ 在 Ω 的某个临域 Ω_1 内连续可微, 且其梯度 $g(x)$ 满足Lipschitz条件, 即存在常数 $L > 0$, 使 $\|g(x) - g(y)\| \leq L\|x - y\|$, $\forall x, y \in \Omega_1$.

在下面的引理中, 我们需要用到著名的Zoutendijk条件^[13], 它对共轭梯度法的收敛性分析有至关重要的作用. 同时, Zoutendijk条件也适用于本文NYHS共轭梯度法的收敛性证明.

引理3.1 若目标函数 $f(x)$ 满足假设(H1), (H2), 考虑NYHS算法. 序列 $\{g_k\}$, $\{d_k\}$ 由该算法生成, α_k 满足标准Wolfe线搜索(2.1), (2.2)式, 则Zoutendijk条件成立, 即, 对于 $\forall k \geq 1$, 有

$$\sum_{k=1}^{\infty} \frac{(g_k^T d_k)^2}{\|d_k\|^2} < +\infty. \quad (3.1)$$

证 由假定(H2)和Wolfe线搜索(2.2)式, 可得:

$$(\sigma - 1) g_k^T d_k \leq (g_{k+1} - g_k)^T d_k \leq \|g_{k+1} - g_k\| \|d_k\| \leq L\alpha_k \|d_k\|^2.$$

$$\text{所以 } \alpha_k \geq \frac{(\sigma - 1) g_k^T d_k}{L\|d_k\|^2}.$$

由Wolfe线搜索(2.1)式, 定理2.1和上式, 可得

$$f(x_k) - f(x_k + \alpha_k d_k) \geq \frac{\rho(1 - \sigma)(g_k^T d_k)^2}{L\|d_k\|^2}.$$

对上式不等式进行求和, 可得

$$\sum_{k=1}^{\infty} \frac{(g_k^T d_k)^2}{\|d_k\|^2} \leq \sum_{k=1}^{\infty} \frac{L}{\rho(1 - \sigma)} (f(x_k) - f(x_k + \alpha_k d_k)) = \frac{L}{\rho(1 - \sigma)} \left(f(x_1) - \lim_{k \rightarrow \infty} f(x_k) \right).$$

由假定(H1)可知, $f(x_k)$ 是一个收敛数列, 所以: $\sum_{k=1}^{\infty} \frac{(g_k^T d_k)^2}{\|d_k\|^2} < \infty$. 证毕, 结论成立.

下面给出算法NYHS的全局收敛性结论.

定理3.1 若目标函数 $f(x)$ 满足假设(H1), (H2), 考虑NYHS算法. 序列 $\{g_k\}$, $\{d_k\}$ 由该算法生成, α_k 满足标准Wolfe线搜索(2.1), (2.2)式, β_k 由(1.8)式产生, 则 $\forall k \geq 1$ 有

$$\liminf_{k \rightarrow \infty} \|g_k\| = 0. \quad (3.2)$$

证 由定理2.1可得, $g_k^T d_k \leq -\frac{\|g_k\|^2}{1+2\|g_k\|}$, 即

$$(-g_k^T d_k)^2 \geq \left(\frac{\|g_k\|^2}{1+2\|g_k\|} \right)^2.$$

当 $k \geq 1$ 时, 用反证法证明, 即若定理3.1不成立, 则存在常数 $\lambda > 0$, 有 $\|g_k\|^2 \geq \lambda$.

共轭梯度法 $\{d_k\}$ 的迭代公式为 $d_k = -g_k + \beta_k d_{k-1}$.

两端取模的平方可得下式, $\|d_k\|^2 = \beta_k^2 \|d_{k-1}\|^2 - 2g_k^T d_k - \|g_k\|^2$.

等式两端同除以 $(g_k^T d_k)^2$, 有

$$\begin{aligned} \frac{\|d_k\|^2}{(g_k^T d_k)^2} &= -\frac{\|g_k\|^2}{(g_k^T d_k)^2} - 2\frac{g_k^T d_k}{(g_k^T d_k)^2} + \beta_k^2 \frac{\|d_{k-1}\|^2}{(g_k^T d_k)^2} = -\frac{\|g_k\|^2}{(g_k^T d_k)^2} - 2\frac{1}{g_k^T d_k} + \beta_k^2 \frac{\|d_{k-1}\|^2}{(g_k^T d_k)^2} \\ &= \beta_k^2 \frac{\|d_{k-1}\|^2}{(g_k^T d_k)^2} + \frac{1}{\|g_k\|^2} - \left(\frac{1}{\|g_k\|} + \frac{\|g_k\|}{g_k^T d_k} \right)^2 \leq \beta_k^2 \frac{\|d_{k-1}\|^2}{(g_k^T d_k)^2} + \frac{1}{\|g_k\|^2} \\ &= \left(\frac{g_k^T g_k + \frac{\|g_k\|}{\|g_{k-1}\|} g_k^T g_{k-1}}{(1+2\|g_k\|)\|d_{k-1}\|} \right)^2 \frac{\|d_{k-1}\|^2}{(g_k^T d_k)^2} + \frac{1}{\|g_k\|^2} \\ &\leq \left(\frac{g_k^T g_k + \frac{\|g_k\|}{\|g_{k-1}\|} g_k^T g_{k-1}}{(1+2\|g_k\|)\|d_{k-1}\|} \right)^2 \frac{\|d_{k-1}\|^2}{\left(\frac{\|g_k\|^2}{1+2\|g_k\|} \right)^2} + \frac{1}{\|g_k\|^2} \\ &\leq \frac{\left(\|g_k\|^2 + \|g_k\|^2 \right)^2}{(1+2\|g_k\|)^2 \|d_{k-1}\|^2} \frac{\|d_{k-1}\|^2 (1+2\|g_k\|)^2}{\|g_k\|^4} + \frac{1}{\|g_k\|^2} = 4 + \frac{1}{\|g_k\|^2} \leq 4 + \frac{1}{\lambda} = \frac{4\lambda+1}{\lambda}. \end{aligned}$$

从而 $\frac{(g_k^T d_k)^2}{\|d_k\|^2} \geq \frac{\lambda}{4\lambda+1}$. 于是

$$\sum_{k=1}^{\infty} \frac{(g_k^T d_k)^2}{\|d_k\|^2} \geq \sum_{k=1}^{\infty} \frac{\lambda}{4\lambda+1} = \infty.$$

上式与引理3.1矛盾, 所以 $\liminf_{k \rightarrow \infty} \|g_k\| = 0$. 结论成立, 证毕.

4. 数值实验

信号处理是一门重要的交叉学科领域, 其在科学研究和工程应用中发挥着关键作用. 它涉及到从各种传感器和设备中收集的信号的处理和分析. 因此, 信号处理在通信, 图像处理, 生物医学工程, 雷达技术等诸多领域都具有广泛应用, 对于促进科学研究和技术发展具有重要意义.

本节, 为了证明NYHS方法的有效性, 我们设计了两个实验, 分别是信号处理中的图像恢复和正则化逻辑回归. 分别将本文方法与其余共轭梯度法应用于这两个实验. 所有代码都是在Matlab 2022a上编写, 并在win10操作系统, Intel(R)Core i5-6500 CPU @ 3.20GHz 3.19GHz 8.00GB内存上运行. 本文标准Wolfe线搜索的参数设置为: $\rho = 0.03$, $\sigma = 0.1$, $\epsilon = 10^{-5}$. SDCG方法的参数设置为 $\mu = 10.75$.

图像恢复是信号处理中的一个重要问题, 它涉及到从损坏或失真的图像中恢复出原始的清晰图像. 图像可能会因为传输过程中的噪声, 压缩, 失真, 模糊等原因而受损, 需要进行恢复处理以获得更好的质量和可视化效果.

用NYHS共轭梯度法恢复椒盐噪声破坏的图像, 并与PRCG方法^[14], SDCG方法^[8], DPRP方法^[9]进行比较, 所有方法均不采用重新开始策略. 其中, PRCG方法不依赖任何线搜索, 它通过计算 $\alpha_k = -\delta \frac{g_k^T d_k}{\|d_k\|^2}$ 获得步长, 其中 $\delta = \frac{\sqrt{99}}{16}$. 其他方法均采用标准wolfe线搜索. 本节用于测试的图像分别是Hill(512×512), Bridge(512×512), Lena(512×512), Peppers(256×256).

表1 图像恢复数值结果

Image	NL	DPRP			SDCG			PRCG			NYHS		
		k	cpu	PSNR	k	cpu	PSNR	k	cpu	PSNR	k	cpu	PSNR
Hill	30%	22	8.86762	34.9807	27	9.90966	34.9794	147	13.7381	34.961	20	8.05377	34.9827
Hill	50%	27	17.0182	32.6801	39	24.0854	32.6824	182	30.4154	32.6146	28	17.4408	32.6967
Hill	70%	35	29.2593	29.8773	54	43.0495	29.8704	258	54.5865	29.7822	36	31.1963	29.8679
Hill	90%	47	53.5586	25.5572	69	71.5961	25.4368	490	130.496	25.5107	45	52.176	25.5469
Bridge	30%	24	9.8162	28.5614	36	13.606	28.5762	157	15.533	28.6245	25	9.58022	28.5697
Bridge	50%	27	18.4504	26.7566	44	26.634	26.7447	211	34.4443	26.679	27	17.4839	26.7684
Bridge	70%	34	31.6299	24.5821	42	33.5902	24.5056	283	57.7503	24.4623	33	29.04	24.5645
Bridge	90%	42	48.4724	21.472	82	85.0015	21.4306	504	135.672	21.4093	50	56.8481	21.4964
Lena	30%	15	6.44653	36.9751	17	7.30122	36.9657	119	11.7534	36.9396	11	5.1867	36.9877
Lena	50%	25	15.5689	34.4639	36	21.5556	34.4619	183	29.3791	34.3865	28	17.4251	34.4774
Lena	70%	33	27.148	31.2092	39	32.1255	31.1694	246	52.1538	31.1136	33	27.5337	31.1998
Lena	90%	47	50.4583	26.155	74	79.9443	26.0744	450	120.402	26.0681	49	54.4399	26.1657
Peppers	30%	25	2.22496	33.1279	35	2.93389	33.108	159	3.60534	33.0304	24	2.21329	33.1433
Peppers	50%	33	4.91937	30.4049	47	6.88825	30.3985	236	8.13463	30.385	28	4.08163	30.4075
Peppers	70%	34	6.64739	27.1969	40	7.13904	27.1786	278	13.1596	27.1758	37	6.87792	27.1738
Peppers	90%	48	10.2418	22.4216	74	13.3988	22.2222	467	22.089	22.2722	47	9.67225	22.4694

本节求解图像恢复问题采用两阶段方法^[15], 这是一种用于检测和恢复图像中的噪声像素的图像处理方法, 这种方法可以在保留图像细节的同时减少噪声的影响, 从而提高图像质量.

第一阶段使用自适应中值滤波器检测噪声像素. 中值滤波器是一种常用的滤波器, 它将每个像素的灰度值替换为其周围邻域像素的中值. 在这个阶段, 中值滤波器被用来检测图像中的噪声像素. 噪声像素通常具有与其周围像素明显不同的灰度值, 因此中值滤波器可以通过将噪声像素替换为其周围像素的中值来减少噪声的影响. 第二阶段通过最小化目标函数恢复前一阶段检测到的噪声. 在这个阶段, 目标函数被定义为将原始图像与第一阶段处理后的图像之间的差异最小化. 通过调整图像中的像素值, 目标函数可以被最小化, 从而恢复第一阶段检测到的噪声.

原始图像 X 的尺寸为 $M \times N$, 则 $A = \{1, 2, \dots, M\} \times \{1, 2, \dots, N\}$ 表示原始图像 X 的索引集. Y 表示污染噪声图像, $y_{i,j}$ 表示在位置 (i, j) 处观察到的像素值. 设 C 表示第一阶段检测到的噪声像素索引集, 显然 $C \subset A$, 令 $V_{i,j}$ 表示位置 (i, j) 处的四个最近邻居的集合. 本文通过最小化下面问题来恢复图像.

$$f(x) = \sum_{(i,j) \in C} \left\{ \sum_{(m,n) \in V_{i,j} \setminus C} 2\varphi_{\alpha}(x_{i,j} - y_{m,n}) + \sum_{(m,n) \in V_{i,j} \cap C} \varphi_{\alpha}(x_{i,j} - x_{m,n}) \right\},$$

其中, $x = [x_{i,j}]_{(i,j) \in C}$ 是长度为 $|C|$ 的列向量, 而 φ_{α} 是一个保边势函数, 我们选择函数 $\varphi_{\alpha}(t) = \sqrt{t^2 + \alpha}$ 且 $\alpha = 100$. 终止条件统一选择如下形式:

$$\frac{|f(x_k) - f(x_{k-1})|}{|f(x_k)|} \leq 10^{-4} \quad \text{或} \quad \frac{\|x_k - x_{k-1}\|}{\|x_k\|} \leq 10^{-4}.$$

噪声信息分别是30%, 50%, 70%, 90% 的椒盐噪声, 引入峰值信噪比(PSNR), 刻画四种方法在图像恢复问题上的有效性. PSNR的计算是基于图像的像素值, 它衡量了原始图像与恢复图像之间的差异. 较高的PSNR值表示恢复图像与原始图像之间的差异较小, 即算法具有较好的恢复效果.

$$\text{PSNR} = 10 \log_{10} \frac{255^2}{\frac{1}{MN} \sum_{i,j} (x_{i,j}^* - x_{i,j})^2},$$

其中, $x_{i,j}^*$ 与 $x_{i,j}$ 分别表示原始图像与被恢复图像的像素值.

图1-2分别表示四种方法对70%, 90%椒盐噪声破坏图像的去噪结果对比图, 表1列出了所有数值结果. 其中, k , cpu和PSNR分别表示算法迭代次数, cpu运行时间, 峰值信噪比. 可以看



图1 四种方法对70%椒盐噪声的去噪结果对比图




图2 四种方法对90%椒盐噪声的去噪结果对比图

出这四种方法都可以恢复被30%, 50%, 70%, 90%椒盐噪声损坏的图像. 其中, 除了个别示例, NYHS方法在提升速度的同时, 能获得更好的PSNR值.

在信号处理中, 正则化逻辑回归是一种常用的分类算法, 用于处理特征变量和目标变量之间的关系. 逻辑回归是一种广泛应用于分类问题的统计学习方法, 它可以用于预测二元变量的概率, 并将其映射到0和1之间. 在信号处理中, 正则化逻辑回归被用于处理具有大量特征的数据集, 以确保模型的泛化能力和抗过拟合能力.

正则化逻辑回归模型^[16]为:

$$\min_{x \in \mathbb{R}^n} f(x) = \frac{1}{N} \sum_{i=1}^N \ln(1 + \exp(-v_i u_i^T x)) + \frac{\eta}{2} \|x\|^2,$$

其中 $\eta > 0$ 表示正则化参数, $(u_i, v_i) \in \mathbb{R}^n \times \{-1, 1\} (i = 1, \dots, N)$ 取自数据集, u_i 是数据变量, v_i 是二进制类, 上述函数为光滑强凸函数.

用NYHS共轭梯度法对上述函数进行优化, 并与PRP方法^[3-4], WYL方法^[6], JMJ方法^[7]进行比较. 表2列出了实验中的9个数据集的相关信息, 初始点由MATLAB中的命令`2 * (rand(n, 1) - 0.5)`生成, 实验中所使用的优化方法均采用标准Wolfe线搜索. 实验中所有的数据集均来自于<https://www.csie.ntu.edu.tw/~cjlin/libsvmtools/datasets/>.

表2 测试实例信息表

No.	Dataset	Data points N	Variables n
1	a1a	30956	123
2	a2a	2265	123
3	a3a	28036	123
4	a4a	12162	123
5	a5a	18890	123
6	a6a	18889	123
7	a7a	16461	123
8	a8a	9865	123
9	a9a	16281	123

表2中的No.表示为数据集的序号, Dataset为9个数据集的名字, Data points N表示数据集中样本数据的个数, Variables n为数据的特征个数. 这些数据集都具有相似的特征和标签结构, 但具体的样本数量和特征维度可能会有所不同. 这些数据集集中的每个样本都由一个标签和一组特征向量组成, 标签的取值为+1或-1, 表示正例和负例. 特征向量中的每个元素可以是二进制值, 实数值或离散值, 具体取决于数据集的特征类型. 此类数据集通常用于测试和评估二分类算法的性能.

表3为采用4种共轭梯度法求解正则化逻辑回归模型的结果, 其中正则化参数 η 取值为0.5, 1, 2, 2.5, NormF表示在共轭梯度算法下所获得的正则化逻辑回归函数的1范数, K 表示算法迭代次数, CPU为运行时间, NF为目标函数迭代次数, NaN代表该方法的迭代次数超过设置的最大迭代值. 在本次实验中, 每个数据集都运行10次, 并取其均值, 最大迭代次数设置为500. 可以看出, 在本节实验中, NYHS共轭梯度法是有效的.

5. 结束语

为了求解大规模无约束优化问题, 本文在其它修正的共轭梯度参数上, 建立一个新的共轭梯度法, NYHS共轭梯度法. 在标准Wolfe线搜索下验证该算法的搜索方向满足下降性, 全局收敛性. 我们将方法应用于信号处理中的图像恢复问题以及正则化逻辑回归模型. 数值实验表明, 本文提出的NYHS共轭梯度法在求解这些问题上是有效的, 有意义的.

表3 正则化逻辑回归结果

η	No.	NormF	PRP			WYL			JMJ			NYHS		
			K	CPU	NF	K	CPU	NF	K	CPU	NF	K	CPU	NF
0.5	1	5.57E-01	111	7.428	644	93	6.014	532	62	2.059	144	60	1.805	129
	2	5.68E-01	127	0.358	749	129	0.33	748	65	0.076	130	65	0.075	130
	3	5.57E-01	109	6.335	627	95	5.338	527	61	1.729	142	59	1.578	127
	4	5.56E-01	109	2.471	637	114	2.664	661	56	0.552	113	57	0.547	115
	5	5.55E-01	105	3.71	604	93	3.178	527	59	1.008	138	57	0.913	123
	6	5.57E-01	116	4.254	688	93	3.123	519	54	0.938	127	59	0.967	127
	7	5.56E-01	107	3.282	616	93	2.834	534	60	0.889	140	58	0.789	125
	8	5.54E-01	105	1.924	610	37	0.498	146	54	0.441	109	55	0.427	111
	9	5.54E-01	105	3.35	604	92	2.614	503	55	0.737	111	55	0.718	111
1	1	5.93E-01	NaN	NaN	NaN	NaN	NaN	NaN	15	0.671	52	13	0.579	41
	2	6.01E-01	NaN	NaN	NaN	17	0.034	64	13	0.015	30	13	0.02	31
	3	5.92E-01	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	13	0.49	41
	4	5.92E-01	20	0.271	64	NaN	NaN	NaN	14	0.154	33	13	0.144	31
	5	5.91E-01	NaN	NaN	NaN	22	0.52	84	14	0.25	33	12	0.223	28
	6	5.92E-01	14	0.269	41	16	0.414	67	11	0.178	25	11	0.193	26
	7	5.92E-01	12	0.168	27	12	0.194	34	13	0.198	31	10	0.155	24
	8	5.90E-01	NaN	NaN	NaN	15	0.174	52	15	0.136	35	13	0.122	31
	9	5.90E-01	NaN	NaN	NaN	22	0.405	76	13	0.181	30	13	1.181	31
2	1	6.25E-01	27	1.577	137	36	2.151	182	22	0.821	64	21	0.764	61
	2	6.31E-01	41	0.112	241	21	0.035	64	23	0.031	67	21	0.033	61
	3	6.25E-01	27	1.463	137	18	0.602	55	22	0.696	64	21	0.639	61
	4	6.24E-01	43	0.97	260	25	0.443	106	23	0.284	67	23	0.313	75
	5	6.23E-01	43	1.585	263	22	0.598	93	23	0.456	67	21	0.406	61
	6	6.25E-01	35	1.206	195	28	0.781	123	20	0.403	58	19	0.371	55
	7	6.24E-01	39	1.195	229	36	1.01	194	22	0.364	64	20	0.33	58
	8	6.23E-01	39	0.725	226	34	0.563	182	22	0.22	64	21	0.229	61
	9	6.23E-01	41	1.183	240	33	0.824	160	22	0.36	64	21	0.36	61
2.5	1	6.34E-01	110	7.971	710	100	16.976	623	55	4.998	163	55	5.053	163
	2	6.39E-01	114	0.322	736	92	0.776	571	57	0.252	169	57	0.314	169
	3	6.34E-01	106	6.193	672	87	7.01	510	55	4.471	163	55	4.498	163
	4	6.33E-01	114	2.688	737	92	2.945	565	57	1.868	169	57	1.831	169
	5	6.33E-01	112	4.608	722	99	4.916	626	57	2.902	169	56	2.865	166
	6	6.34E-01	104	4.11	676	100	5.157	626	53	2.702	157	53	1.531	157
	7	6.33E-01	112	9.422	727	94	4.454	580	56	2.494	166	56	1.389	166
	8	6.33E-01	110	3.157	707	55	1.178	288	56	0.955	166	55	0.751	163
	9	6.33E-01	110	4.787	702	90	4.881	545	56	2.491	166	56	1.699	166

参考文献:

[1] DAI Y H, YUAN Y X. A nonlinear conjugate gradient method with a strong convergence property[J]. SIAM J. Optim., 1999, 10(1): 177-182.

[2] FLETCHER R, REEVES C M. Function minimization by conjugate gradients[J]. Comput. J., 1964, 7(2): 149-154.

[3] POLAK E, RIBI ÉRE G. Note sur la convergence de méthodes de directions conjuguées[J]. Rev. Francaise Informat Recherche opérationnelle, 1969, 3(16): 35-43.

[4] POLYAK B T. The conjugate gradient method in extreme problems[J]. U.S.S.R. Comput. Math. and Math. Phys., 1969, 9(4): 94-112.

[5] HESTENES M R, STIEFEL E. Method of conjugate gradient for solving linear equations[J]. J.Res. Nat. Bur. Stand., 1952, 49: 409-436.

- [6] 刘鹏杰, 吴彦强, 邵枫, 等. 两个带重启方向的改进HS型共轭梯度法[J]. 数学物理学报, 2023, 43(2): 570-580.
- [7] WU X, SHAO H, LIU P, et al. An efficient conjugate gradient-based algorithm for unconstrained optimization and its projection extension to large-scale constrained nonlinear equations with applications in signal recovery and image denoising problems[J]. J. Comput. Appl. Math., 2023, 422: 114879.
- [8] DONG X. A modified nonlinear Polak-Ribière-Polyak conjugate gradient method with sufficient descent property[J]. Calcolo, 2020, 57(3): 30.
- [9] WEI Z, YAO S, LIU L. The convergence properties of some new conjugate gradient methods[J]. Appl. Math. Comput., 2006, 183(2): 1341-1350.
- [10] 江羨珍, 马国栋, 简金宝. Wolfe线搜索下一个新的全局收敛共轭梯度法[J]. 工程数学学报, 2011, 28(6): 779-786.
- [11] 张海斌, 张鑫, 张芳. 一种求解非线性无约束优化问题的充分下降的共轭梯度法[J]. 运筹学学报, 2018, 22(3): 59-68.
- [12] DAI Z F, WEN F H. Another improved Wei-Yao-Liu nonlinear conjugate gradient method with sufficient descent property[J]. Appl. Math. Comput., 2012, 218(14): 7421-7430.
- [13] ZOUTENDIJK G. Nonlinear programming, computational methods[J]. Integer and nonlinear programming, 1970, 143: 37-86.
- [14] CAI J F, CHAN R H, DI FIORE C. Minimization of a detail-preserving regularization functional for impulse noise removal[J]. J. Math. Imaging Vis., 2007, 29: 79-91.
- [15] CAI J F, CHAN R, MORINI B. Image Processing Based on Partial Differential Equations: Proceedings of the International Conference on PDE-Based Image Processing and Related Inverse Problems[M]. Berlin Heidelberg: Springer, 2007.
- [16] LUO H. Accelerated primal-dual methods for linearly constrained convex optimization problems[J]. arXiv preprint, 2021, arXiv: 2109.12604.

A Novel Conjugate Gradient Method Under Wolfe Line Search and Its Application

LIU Ying^{1,2,3}, ZHU Zhibin^{1,2,3}, DING Yuehong^{1,2,3}, HUANG Jiaqi^{1,2,3}

(1. School of Mathematics and Computational Science, Guilin University of Electronic Technology, Guilin 541004, China; 2. Key Laboratory of Data Analysis and Computation in Guangxi Higher Education, Guilin 541004, China; 3. Guangxi Applied Mathematics Center, Guilin University of Electronic Technology, Guilin 541004, China)

Abstract: Considering the unconstrained optimization problem, a new conjugate gradient method named NYHS conjugate gradient method is proposed in this paper. The descent property and global convergence of the method are proved under the standard Wolfe line search. The algorithm proposed in this paper is applied to two experiments in signal processing, namely image restoration and regularized logistic regression model. The results demonstrate the effectiveness of the proposed method.

Key words: Unconstrained optimization; Conjugate gradient method; Global convergence; Image restoration; Regularized logistic regression