

一种新的求解含有 l_1 范数 优化问题的共轭梯度法*

杨艳雪 杜守强[†] 吕施春

(青岛大学数学与统计学院, 青岛 266071)

([†]E-mail: sqdu@qdu.edu.cn)

摘要 本文考虑了含有 l_1 范数优化问题的求解方法, 此类问题在压缩感知等研究领域有广泛应用. 基于光滑函数, 文中给出了一种新的求解此类含有 l_1 范数优化问题的共轭梯度法. 在一般条件下分析了算法的全局收敛性, 相关的数值结果也表明了算法的有效性.

关键词 l_1 范数; 共轭梯度法; 全局收敛

MR(2020)主题分类 90C30; 65K05

中图分类 0221

DOI: 10.20142/j.cnki.amas.202401066

1 介绍

本文考虑如下结构含有 l_1 范数的优化问题

$$\min_{\mathbf{x}} \quad \lambda \|\mathbf{x}\|_1 + \frac{1}{2} \|b - A\mathbf{x}\|_2^2, \quad \mathbf{x} \in \mathbb{R}^n, \quad (1)$$

其中 $\mathbf{x} = (x_1, x_2, \dots, x_n) \in \mathbb{R}^n$, $A \in \mathbb{R}^{m \times n}$, $b \in \mathbb{R}^m$, $\lambda > 0$. 此类带有 l_1 范数的优化问题在求解压缩感知等问题中得到了广泛应用^[1-20], 如: 含有零范数的优化问题^[18]

$$\begin{aligned} \min \quad & \|\mathbf{x}\|_0 \\ \text{s.t.} \quad & b = A\mathbf{x}, \end{aligned} \quad (2)$$

其中 $\|\mathbf{x}\|_0$ 为零范数, 表示 $\mathbf{x}$ 中非零分量的个数, 问题为NP难问题, 在一定条件下转化

本文 2021 年 10 月 12 日收到. 2023 年 10 月 11 日收到修改稿.

*山东省自然科学基金(ZR2022MA001, ZR2016AM29)资助项目.

[†]通讯作者.

为

$$\begin{aligned} \min \quad & \|\mathbf{x}\|_1 \\ \text{s.t.} \quad & b = A\mathbf{x}, \end{aligned} \quad (3)$$

其中 $\|\mathbf{x}\|_1 = \sum_{i=1}^n |x_i|$, 问题(3)可以由(1)求出转化的最优解.

自2006年 Donoho 等人提出与 l_1 范数相关的优化问题以来(见[1-6]), 广大学者对问题(1), (2), (3)以及相关优化问题进行了深入的研究(见[7-22]), 例如: [15] 提出一种带有参数正则化过程的迭代加权 l_1 范数优化算法, 并验证了算法的有效性; [16] 系统论述了交替方向法在压缩感知信号恢复 l_1 范数问题中的应用; [17] 通过一维收缩或 Euclidean 投影得到 l_1 范数转化问题的显式解, 并提出一种全局收敛的交替方向法; [18] 提出一种三项 PRP 共轭梯度法求解信号恢复问题, 相关的数值实验表明了算法的有效性; [19] 给出一种光滑梯度法求解 l_1 范数优化问题, 并且通过数值算例验证了算法的可行性与有效性; [20] 基于最小化源信号“尾部”支撑集的 l_1 范数, 提出部分支撑集的 l_1 范数稀疏重构算法, 并验证了算法的求解精度. 通过以上相关文献的分析可知, 梯度类算法和光滑化算法在求解此类问题中得到了研究重视. 共轭梯度法^[23-26]以及光滑化算法^[27-29]具有算法结构清晰, 计算存储量相对较少等优点而被广泛使用. 因此本文结合光滑化技术与新型共轭梯度法对含有 l_1 范数优化问题的求解算法进行研究, 给出了一种求解此类问题的共轭梯度法, 算法只需一阶求导计算, 光滑函数结构简单易于实现.

本文的结构如下: 第二部分给出问题(1)的相关函数光滑化过程; 第三部分给出了求解光滑化后优化问题的共轭梯度法, 并分析了算法的全局收敛性及梯度相关的性质; 第四部分给出相关的数值实验结果; 第五部分给出结论.

2 预备知识

本部分给出问题(1)的光滑化过程. 对于(1)式有多种光滑化方法, 由[18], 我们选取

$$\psi_i(\mu, x_i) = \sqrt{4\mu^2 + x_i^2} \quad (4)$$

对(1)中的 $\|\mathbf{x}\|_1$ 光滑化, (4)式中的 μ 为光滑因子, 则(1)转化为

$$\min_{\mathbf{x}} \quad \lambda \sum_{i=1}^n \psi_i(\mu, x_i) + \frac{1}{2} \|b - A\mathbf{x}\|_2^2, \quad \mathbf{x} \in \mathbb{R}^n. \quad (5)$$

记

$$f(\mathbf{x}) := \lambda \|\mathbf{x}\|_1 + \frac{1}{2} \|b - A\mathbf{x}\|_2^2, \quad (6)$$

则

$$f_{\mu}(\mathbf{x}) := \lambda \sum_{i=1}^n \psi_i(\mu, x_i) + \frac{1}{2} \|b - A\mathbf{x}\|_2^2. \quad (7)$$

定义 2.1^[27] 设 $E(\mathbf{x}) : \mathbb{R}^n \rightarrow \mathbb{R}$ 为非光滑函数, 称 $E_{\mu}(\mathbf{x}) : \mathbb{R}^n \rightarrow \mathbb{R}$ 是 $E(\mathbf{x})$ 的光滑函数, $\Leftrightarrow$ 对 $\forall \mathbf{x} \in \mathbb{R}^n, \mu > 0, \exists \kappa > 0$ 使得

$$|E_{\mu}(\mathbf{x}) - E(\mathbf{x})| \leq \kappa \mu.$$

命题 2.1 设 $f(\mathbf{x}), f_{\mu}(\mathbf{x})$ 由(6)与(7)定义, 则

$$|f_{\mu}(\mathbf{x}) - f(\mathbf{x})| \leq \lambda \sum_{i=1}^n (\sqrt{(2\mu + |x_i|)^2} - |x_i|).$$

证 由(6),(7)得

$$\begin{aligned} |f_{\mu}(\mathbf{x}) - f(\mathbf{x})| &= \left| \left(\lambda \sum_{i=1}^n \psi_i + \frac{1}{2} \|b - A\mathbf{x}\|_2^2 \right) - \left(\lambda \sum_{i=1}^n |x_i| + \frac{1}{2} \|b - A\mathbf{x}\|_2^2 \right) \right| \\ &= \lambda \sum_{i=1}^n (\sqrt{4\mu^2 + x_i^2} - |x_i|) \leq \lambda \sum_{i=1}^n (\sqrt{(2\mu + |x_i|)^2} - |x_i|) \end{aligned}$$

命题成立, 证毕.

3 一种新的共轭梯度法

共轭梯度法因其算法结构简单、存储量少等特点而被广泛使用. 本部分基于[25,26], 针对问题(5)给出一种新的充分下降的共轭梯度法及算法相关的收敛性分析. 令 d_k 为搜索方向, α_k 为步长, $\tilde{g}(\mathbf{x})$ 表示 $f_{\mu}(\mathbf{x})$ 在 $\mathbf{x}$ 处的梯度, 即: $\tilde{g}(\mathbf{x}) = \nabla f_{\mu}(\mathbf{x})$, 并且在以下部分 $\tilde{g}(\mathbf{x})$ 将一直表示 $f_{\mu}(\mathbf{x})$ 在 $\mathbf{x}$ 处的梯度, β_k 是一个参数.

令

$$d_k = \begin{cases} -\tilde{g}_k, & \text{if } k = 0, \\ -\tilde{g}_k + \beta_k d_{k-1}, & \text{if } k > 0, \end{cases} \quad (8)$$

以及

$$\beta_k = \frac{\|\tilde{g}_k\|^2}{\vartheta (\|\tilde{g}_k\|^2 + \|d_{k-1}\|^2)}, \quad \vartheta > \frac{1}{2}. \quad (9)$$

下面我们给出新的共轭梯度法.

算法 3.1

步 0. 给定 $0 < \sigma \ll 1$ 以及 $\mathbf{x}_0$, 计算 $\tilde{g}_0 = \nabla f_{\mu}(\mathbf{x}_0)$. 令 $k := 0$.

步 1. 若 $\|\tilde{g}_k\| \leq \sigma$, 则停, 输出 $\mathbf{x}^* = \mathbf{x}_k$.

步 2. 由(8)与(9)计算搜索方向 d_k .

步 3. 采用以下线搜索求步长 α_k , 满足

$$f_{\mu}(\mathbf{x}_k + \alpha_k d_k) \leq f_{\mu}(\mathbf{x}_k) + \delta \alpha_k \tilde{g}_k^T d_k, \quad (10)$$

其中 $\alpha_k = \max\{\rho^j \frac{t|\tilde{g}_k^T d_k|}{\|d_k\|^2}, j=0, 1, 2, \dots\}$, $0 < \rho, t, \delta < 1$ 为常数.

步 4. 令 $\mathbf{x}_{k+1} := \mathbf{x}_k + \alpha_k d_k$, $\mu_{k+1} = \gamma \mu_k$, $0 < \gamma < 1$, 计算 $\tilde{g}_{k+1} = \nabla f_{\mu}(\mathbf{x}_{k+1})$.
令 $k := k + 1$, 转步1.

如无特别说明, 本文总假设序列 $\{\mathbf{x}_k\}$, $\{\tilde{g}_k\}$ 和 $\{d_k\}$ 是由算法3.1产生的. 首先给出证明算法3.1全局收敛所需的引理. 与[18]中引理3.1与引理3.2类似, 我们给出如下引理.

引理 3.1 水平集 $\Omega = \{\mathbf{x} \in \mathbb{R}^n | f_{\mu}(\mathbf{x}) \leq f_{\mu}(\mathbf{x}_0)\}$ 有界.

证 反证法. 设 Ω 无界, 则存在一个 K_1 , 存在 $\mathbf{x}_k = (x_{k1}, x_{k2}, \dots, x_{kn})^T$, 使得 $\|\mathbf{x}_k\| \rightarrow \infty, k \rightarrow \infty, k \in K_1$, 由(7)可知

$$f_{\mu}(\mathbf{x}_k) = \lambda \sum_{i=1}^n \psi_i(\mu, x_{ki}) + \frac{1}{2} \|b - A\mathbf{x}_k\|_2^2 = \lambda \sum_{i=1}^n \sqrt{4\mu^2 + x_{ki}^2} + \frac{1}{2} \|b - A\mathbf{x}_k\|_2^2,$$

当 $\|\mathbf{x}_k\| \rightarrow \infty, k \rightarrow \infty, k \in K_1$ 时, 有 $\lambda \sum_{i=1}^n \sqrt{4\mu^2 + x_{ki}^2} \rightarrow \infty$, 与 $f_{\mu}(\mathbf{x}_k) \leq f_{\mu}(\mathbf{x}_0)$ 矛盾, 证毕.

引理 3.2 水平集 Ω 的邻域 U 中, $f_{\mu}(\mathbf{x})$ 连续可微, 且梯度Lipschitz连续, 即 $\exists L > 0$, 有

$$\|\tilde{g}(\tau) - \tilde{g}(v)\| \leq L \|\tau - v\|, \quad \forall \tau, v \in U. \quad (11)$$

证 由(4), (7)以及[18], 可知

$$|\psi''(\mu, x_i)| < \frac{1}{2\mu},$$

设 $\tau_i < v_i, i = 1, \dots, n$, 有

$$\begin{aligned} & \|\tilde{g}(\tau) - \tilde{g}(v)\| \\ &= \left\| \lambda \sum_{i=1}^n [\nabla \psi(\mu, \tau_i) - \nabla \psi(\mu, v_i)] + A^T(A\tau - b) - A^T(Av - b) \right\| \\ &\leq \lambda \sum_{i=1}^n |\psi''(\mu, \tau_i + \eta(v_i - \tau_i))| \cdot \|\tau - v\| + \|A\|^2 \|\tau - v\| \\ &\leq \frac{n\lambda}{2\mu} \|\tau - v\| + \|A\|^2 \|\tau - v\|, \end{aligned}$$

$\exists L > 0$, 使得(11)成立, 证毕.

引理 3.3 若 $\{\mathbf{x}_k\}$ 由算法3.1产生, 则 $\exists c > 0$, 使

$$\tilde{g}_k^T d_k \leq -c \|\tilde{g}_k\|^2 < 0. \quad (12)$$

证 分两种情况证明(12).

(i) $k = 0$ 时, 由(8), 可得 $\tilde{g}_k^T d_k = \tilde{g}_0^T (-\tilde{g}_0) = -\|\tilde{g}_0\|^2 < 0$, 此情况成立;

(ii) $k \geq 1$ 时, 由(8)与(9), 可知

$$\begin{aligned}\tilde{g}_k^T d_k &= \tilde{g}_k^T (-\tilde{g}_k + \beta_k d_{k-1}) = -\|\tilde{g}_k\|^2 + \beta_k \tilde{g}_k^T d_{k-1} \\ &\leq -\|\tilde{g}_k\|^2 + \frac{1}{2} \beta_k (\|\tilde{g}_k\|^2 + \|d_{k-1}\|^2) \\ &= -\|\tilde{g}_k\|^2 + \frac{1}{2} \frac{\|\tilde{g}_k\|^2}{\vartheta (\|\tilde{g}_k\|^2 + \|d_{k-1}\|^2)} (\|\tilde{g}_k\|^2 + \|d_{k-1}\|^2) \\ &= \left(\frac{1}{2\vartheta} - 1 \right) \|\tilde{g}_k\|^2,\end{aligned}$$

$\exists c > 0$, 使(12)成立, 证毕.

引理 3.4 若 $\{\mathbf{x}_k\}$ 由算法3.1产生, 则 $\exists c_1 > 0$, 使

$$\alpha_k \geq c_1 \frac{\|\tilde{g}_k\|^2}{\|d_k\|^2}.$$

证 分两种情况证明.

(i) 当 $j = 0$, 对应 $\alpha_k = \frac{t|\tilde{g}_k^T d_k|}{\|d_k\|^2}$, 由Cauchy-Schwarz 不等式以及(8), 则 $\|\tilde{g}_k\| \leq \|d_k\|$, $\|\tilde{g}_k\|^2 \leq |\tilde{g}_k^T d_k|$, 取 $c_1 = t$ 成立;

(ii) 当 $j \neq 0$, 对应 $0 < \alpha_k < \frac{t|\tilde{g}_k^T d_k|}{\|d_k\|^2}$, 由算法3.1知 $\rho^{-1}\alpha_k$ 不满足(10), 即

$$f_\mu(\mathbf{x}_k + \rho^{-1}\alpha_k d_k) > f_\mu(\mathbf{x}_k) + \delta \rho^{-1}\alpha_k \tilde{g}_k^T d_k.$$

由中值定理和引理3.2可得存在 $\epsilon_k \in (0, 1)$ 使得

$$\begin{aligned}& f_\mu(\mathbf{x}_k + \rho^{-1}\alpha_k d_k) - f_\mu(\mathbf{x}_k) \\ &= \rho^{-1}\alpha_k \tilde{g}(\mathbf{x}_k + \epsilon_k \rho^{-1}\alpha_k d_k)^T d_k = \rho^{-1}\alpha_k \tilde{g}_k^T d_k + \rho^{-1}\alpha_k [\tilde{g}(\mathbf{x}_k + \epsilon_k \rho^{-1}\alpha_k d_k) - \tilde{g}_k]^T d_k \\ &\leq \rho^{-1}\alpha_k \tilde{g}_k^T d_k + L \rho^{-2} \alpha_k^2 \epsilon_k^2 \|d_k\|^2 \leq \rho^{-1}\alpha_k \tilde{g}_k^T d_k + L \rho^{-2} \alpha_k^2 \|d_k\|^2.\end{aligned}$$

因此

$$\rho^{-1}\alpha_k \tilde{g}_k^T d_k + L \rho^{-2} \alpha_k^2 \|d_k\|^2 > \delta \rho^{-1}\alpha_k \tilde{g}_k^T d_k,$$

即

$$(1 - \delta) \rho^{-1}\alpha_k \tilde{g}_k^T d_k > -L \rho^{-2} \alpha_k^2 \|d_k\|^2 > \frac{\rho(1 - \delta) \tilde{g}_k^T d_k}{-L \|d_k\|^2}.$$

由引理3.3有

$$\alpha_k > \frac{\rho c (1 - \delta) \|\tilde{g}_k\|^2}{L \|d_k\|^2},$$

令 $c_1 = \min\{t, \frac{\rho c(1-\delta)}{L}\}$, 引理成立, 证毕.

引理 3.5 若 $\{\mathbf{x}_k\}$ 由算法3.1产生, 则

$$\sum_{k \geq 0} \frac{(\tilde{g}_k^T d_k)^2}{\|d_k\|^2} < \infty.$$

证 由引理3.1, 引理3.3以及引理3.4可知引理成立, 证毕.

定理 3.1 若 $\{\mathbf{x}_k\}$, $\{d_k\}$ 是由算法3.1 产生, 则

$$\liminf_{k \rightarrow \infty} \|\tilde{g}_k\| = 0. \quad (13)$$

证 反证法 假设(13)不成立, 则存在常数 ι 使得

$$\|\tilde{g}_k\| \geq \iota, \quad \forall k \geq 0.$$

由(8), 可知

$$d_k + \tilde{g}_k = \beta_k d_{k-1},$$

则

$$\|d_k\|^2 + 2\tilde{g}_k^T d_k + \|\tilde{g}_k\|^2 = \beta_k^2 \|d_{k-1}\|^2, \quad \|d_k\|^2 = \beta_k^2 \|d_{k-1}\|^2 - 2\tilde{g}_k^T d_k - \|\tilde{g}_k\|^2,$$

两边同时除以 $(\tilde{g}_k^T d_k)^2$, 由(8),(9),(12)以及Cauchy-Schwarz 不等式可得

$$\begin{aligned} \frac{\|d_k\|^2}{(\tilde{g}_k^T d_k)^2} &= \frac{\beta_k^2 \|d_{k-1}\|^2}{(\tilde{g}_k^T d_k)^2} - \frac{2\tilde{g}_k^T d_k}{(\tilde{g}_k^T d_k)^2} - \frac{\|\tilde{g}_k\|^2}{(\tilde{g}_k^T d_k)^2} \\ &= \frac{\beta_k^2 \|d_{k-1}\|^2}{(\tilde{g}_k^T d_k)^2} - \left(\frac{1}{\|\tilde{g}_k\|} + \frac{\|\tilde{g}_k\|}{\tilde{g}_k^T d_k} \right)^2 + \frac{1}{\|\tilde{g}_k\|^2} \\ &\leq \frac{\beta_k^2 \|d_{k-1}\|^2}{(\tilde{g}_k^T d_k)^2} + \frac{1}{\|\tilde{g}_k\|^2} \\ &= \frac{\|\tilde{g}_k\|^4}{\vartheta^2 (\|\tilde{g}_k\|^2 + \|d_{k-1}\|^2)^2} \frac{\|d_{k-1}\|^2}{(\tilde{g}_k^T d_k)^2} + \frac{1}{\|\tilde{g}_k\|^2} \\ &\leq \frac{1}{4c^2} \frac{(\tilde{g}_k^T d_k)^2}{\vartheta^2 \|d_{k-1}\|^2 \|\tilde{g}_k\|^2} \frac{\|d_{k-1}\|^2}{(\tilde{g}_k^T d_k)^2} + \frac{1}{\|\tilde{g}_k\|^2} \\ &= \frac{1}{4c^2 \vartheta^2} \frac{1}{\|\tilde{g}_k\|^2} + \frac{1}{\|\tilde{g}_k\|^2} = \frac{4c^2 \vartheta^2 + 1}{4c^2 \vartheta^2} \frac{1}{\|\tilde{g}_k\|^2}, \end{aligned}$$

则 $\exists s > 0$, 使

$$\frac{\|d_k\|^2}{(\tilde{g}_k^T d_k)^2} \leq \frac{s}{\|\tilde{g}_k\|^2} \leq \frac{s}{\iota^2}, \quad \sum_{k=1}^{\infty} \frac{(\tilde{g}_k^T d_k)^2}{\|d_k\|^2} \geq \sum_{k=1}^{\infty} \frac{\iota^2}{s} = \infty,$$

上式与引理3.5矛盾, 证毕.

根据[28-30], 我们给出 $\partial f(\mathbf{x})$ 与 $\tilde{g}(\mathbf{x})$ 的相关性质分析, 其中 $\partial f(\mathbf{x})$ 表示 f 在 $\mathbf{x}$ 处的广义梯度, 定义为 $\partial f(\mathbf{x}) = \text{conv}\left\{\lim_{x_i \rightarrow x, x_i \in D_f} \nabla f(x_i)\right\}$, 其中 conv 表示集合的凸包, D_f 表示 f 在可微点处的集合.

定理 3.2 若 $\{\mathbf{x}_k\}$ 由算法3.1产生, $x_k \rightarrow x^*, k \rightarrow \infty$, 则有 $0 \in \partial f(\mathbf{x}^*)$, x^* 为Clarke稳定点.

证 由[29]的定理1可知, 对于 $K \subseteq \{1, 2, 3, \dots\}$, 得

$$\forall V \in \left\{V \mid V = \lim_{i \rightarrow \infty, i \in K} \nabla f(x_i, \mu_i), x_i \rightarrow x^*, \mu_i \downarrow 0\right\},$$

有 $V \in \partial f(x^*)$. 由定理3.1可得 $0 \in \partial f(\mathbf{x}^*)$, x^* 为 f 的Clarke稳定点, 证毕.

4 数值试验

为了验证算法3.1的有效性, 本部分给出了算法3.1的数值实验, 其中算例来源于[14,19,22]. 在以下数值实验中, 初始点为随机选取, 并将计算结果与[19]中光滑梯度法的结果进行比较. 所有代码在Intel(R) Core(TM) i5-7200U CPU(2.50 GHz), RAM 4.00GB, Matlab (R2016a)的环境下运行. 所涉及参数设定为: $\sigma = 10^{-10}$, $\delta = 0.005$, $\vartheta = 5.5$, $\rho = 0.7$, $\mu_0 = 0.5$, $\gamma = 0.05$, $t = 0.5$. 终止条件为 $\|\tilde{g}_k\| < 10^{-10}$ 或 $k = 100000$.




图 1. 算法3.1求解例4.1的数值结果.




图 2. [19]中光滑梯度法求解例4.1的数值结果.

例 4.1 考虑优化问题(1), 其中 $\lambda = 5$, $b = (2, 4, 1, 7)^T$,

$$A = \begin{pmatrix} 3 & 5 & 8 & 4 & 1 & 5 \\ 2 & 9 & 6 & 5 & 7 & 4 \\ 3 & 4 & 7 & 2 & 1 & 6 \\ 8 & 9 & 6 & 5 & 7 & 4 \end{pmatrix}.$$

由算法3.1我们得到最优解为 $(0.3463, 0.0848, 0.0000, 0.0000, 0.3724, 0.0000)^T$. 图1和图2给出了两种算法求解过程中目标函数值随迭代次数变化的对比情况.

例 4.2 考虑优化问题(1), 其中 $\lambda = 10$, $b = (1, 1, \dots, 1)^T$,

$$A = \begin{pmatrix} 4 & -1 & 0 & \cdots & 0 & 1 & \cdots & 1 \\ -1 & 4 & -1 & \cdots & \vdots & \vdots & \cdots & \vdots \\ 0 & -1 & 4 & \ddots & \vdots & \vdots & \cdots & \vdots \\ \vdots & \ddots & \ddots & -1 & \vdots & \vdots & \cdots & \vdots \\ 0 & \cdots & \cdots & -1 & 4 & 1 & \cdots & 1 \end{pmatrix}_{m \times n}.$$

当 $m = 110$, $n = 120$ 时, 通过两种算法进行运算, 目标函数值随迭代次数变化的对比情况如图3和图4所示; 当 $m = 210$, $n = 220$ 与 $m = 500$, $n = 510$ 时, 算法3.1运行产生的结果如图5和图6所示.




图 3. 算法3.1求解例4.2的数值结果,

$m = 110$, $n = 120$.




图 4. [19]中光滑梯度法求解例4.2的数值结果,

$m = 110$, $n = 120$.




图 5. 算法3.1求解例4.2的数值结果,

$m = 210$, $n = 220$.




图 6. 算法3.1求解例4.2的数值结果,

$m = 500$, $n = 510$.

例 4.3 考虑优化问题(1), 其中 $\lambda = 10$, $b = (1, 1, \dots, 1)^T$,

$$A = \begin{pmatrix} 1 & 2 & 2 & \cdots & 2 & 1 & \cdots & 1 \\ 0 & 1 & 2 & \cdots & 2 & \vdots & \cdots & \vdots \\ 0 & 0 & 1 & \ddots & 2 & \vdots & \cdots & \vdots \\ \vdots & \vdots & \vdots & \ddots & \vdots & \vdots & \cdots & \vdots \\ 0 & 0 & 0 & \cdots & 1 & 1 & \cdots & 1 \end{pmatrix}_{m \times n}.$$

当 $m = 100$, $n = 110$ 时, 通过两种算法进行运算, 目标函数值随迭代次数变化的对比情况如图7和图8所示; 当 $m = 150$, $n = 160$ 与 $m = 500$, $n = 510$ 时, 算法3.1运行结果如图9和10所示.

当 $m = 100$, $n = 110$ 时, 通过两种算法进行运算, 目标函数值随迭代次数变化的对比情况如图11 和图12 所示; 当 $m = 150$, $n = 160$ 与 $m = 500$, $n = 510$ 时, 算法3.1运行结果如图13和14所示.




图 7. 算法3.1求解例4.3的数值结果,

$m = 100, n = 110.$




图 8. [19]中光滑梯度法求解例4.3的数值结果,

$m = 100, n = 110.$




图 9. 算法3.1求解例4.3的数值结果,

$m = 150, n = 160.$




图 10. 算法3.1求解例4.3的数值结果,

$m = 500, n = 510.$

例 4.4 考虑优化问题(1), 其中 $\lambda = 10$, $b = (1, 1, \dots, 1)^T$,

$$A = \begin{pmatrix} \frac{1}{n} & 0 & 0 & 0 & \dots & 0 & 1 & \dots & 1 \\ 0 & \frac{2}{n} & 0 & 0 & \dots & 0 & \vdots & \dots & \vdots \\ 0 & 0 & \frac{3}{n} & 0 & \dots & 0 & \vdots & \dots & \vdots \\ 0 & 0 & 0 & \frac{4}{n} & \dots & 0 & \vdots & \dots & \vdots \\ \vdots & \vdots & \vdots & \vdots & \ddots & \vdots & \vdots & \dots & \vdots \\ 0 & 0 & 0 & 0 & \dots & 1 & 1 & \dots & 1 \end{pmatrix}_{m \times n}.$$




图 11. 算法3.1求解例4.4的数值结果,
 $m = 100, n = 110$.




图 12. [19]中光滑梯度法求解例4.4的数值结果,
 $m = 100, n = 110$.




图 13. 算法3.1求解例4.4的数值结果,
 $m = 150, n = 160$.




图 14. 算法3.1求解例4.4的数值结果,
 $m = 500, n = 510$.

例 4.5 取参数值为 $n = 2^8$, $m = 2^6$, 峰值是100个, 用算法3.1对此信号恢复问题进行求解, 与[14,19,22]中结果的比较情况如图15所示.




图 15 例4.5数值结果.

5 小结

本文考虑了一类含有 l_1 范数的优化问题, 并且给出了一种新的求解此类问题的共轭梯度法及理论分析, 从数值实验结果可以看出算法的有效性. 同时我们新给出的算法3.1也可用于求解相关的优化问题, 未来我们将致力于此类含有 l_1 范数优化问题的模型与算法的拓展研究, 使得模型与算法的应用更加广泛.

参 考 文 献

- [1] Donoho D L. For most large underdetermined systems of equations, the minimal l_1 -norm solution approximates the sparsest near-solution. *Communications on Pure and Applied Mathematics*, 2006, 59(7): 907-934
- [2] Candès E J. Compressive sampling. *Proceedings of International Congress of Mathematicians*, 2006, 3: 1433-1452
- [3] Candès E J, Tao T. Near-optimal signal recovery from random projections: universal encoding strate-

- gies. *IEEE Transactions on Information Theory*, 2006, 52(12): 5406–5425
- [4] Donoho D L. Compressed sensing. *IEEE Transactions on Information Theory*, 2006, 52(4): 1289–1306
- [5] Candès E J, Romberg J K, Tao T. Stable signal recovery from incomplete and inaccurate measurements. *Communications on Pure and Applied Mathematics*, 2006, 59(8): 1207–1223
- [6] Candès E J, Romberg J K, Tao T. Robust uncertainty principles: exact signal reconstruction from highly incomplete frequency information. *IEEE Transactions on Information Theory*, 2006, 52(2): 489–509
- [7] Yang A, Ganesh A, Sastry S, Ma Y. Fast L_1 -minimization algorithms and an application in robust face recognition: a review. *Proceedings of the 17th IEEE International Conference on Image Processing*, 2010, 1849–1852
- [8] Padovani S, Tepper M, Jacobo-Berlles J. Face recognition on partially occluded images using compressed sensing. *Pattern Recognition Letters*, 2014, 36(1): 235–242
- [9] Wright J, Yang A Y, Ganesh A, Sastry S S, Ma Y. Robust face recognition via sparse representation. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 2009, 31(2): 201–227
- [10] 张勇, 叶万洲. 一种求解弹性 $l_2 - l_q$ 正则化问题的方法. 运筹学学报, 2016, 20(4): 11–20
(Zhang Y, Ye W Z. An algorithm for elastic $l_2 - l_q$ regularization. *Operations Research Transactions*, 2016, 20(4): 11–20)
- [11] 赵晨, 罗自炎, 修乃华. 稀疏优化理论与算法若干新进展. 运筹学学报, 2020, 24(4): 1–24
(Zhao C, Luo Z Y, Xiu N H. Some advances in theory and algorithms for sparse optimization. *Operations Research Transactions*, 2020, 24(4): 1–24)
- [12] Figueiredo M A T, Nowak R D, Wright S J. Gradient projection for sparse reconstruction: application to compressed sensing and other inverse problems. *IEEE Journal of Selected Topics in Signal Processing*, 2007, 1(4): 586–597
- [13] 文再文, 印卧涛, 刘歆, 张寅. 压缩感知和稀疏优化简介. 运筹学学报, 2012, 16(3): 49–64
(Wen Z W, Yin W T, Liu X, Zhang Y. Introduction to compressive sensing and sparse optimization. *Operations Research Transactions*, 2012, 16(3): 49–64)
- [14] Xiao Y H, Wang Q Y, Hu Q J. Non-smooth equations based method for l_1 -norm problems with applications to compressed sensing. *Nonlinear Analysis*, 2011, 74(11): 3570–3577
- [15] 杨扬, 刘哲, 吕方园. 一种迭代加权 l_1 范数的信号优化恢复方法. 计算机工程与应用, 2010, 46(3): 128–130
(Yang Y, Liu Z, Lv F Y. Signal recovery based on iterative weighted l_1 norm. *Computer Engineering and Applications*, 2010, 46(3): 128–130)
- [16] Yang J F, Zhang Y. Alternating direction algorithms for L_1 -problems in compressive sensing. *SIAM Journal on Scientific Computing*, 2011, 33(1): 250–278
- [17] Xiao Y H, Zhu H, Wu S-Y. Primal and dual alternating direction algorithms for l_1 - l_1 -norm minimization problems in compressive sensing. *Computational Optimization and Applications*, 2013, 54(2): 441–459
- [18] Wu C Y, Zhan J M, Lu Y, Chen J-S. Signal reconstruction by conjugate gradient algorithm based on smoothing l_1 -norm. *Calcolo*, 2019, 56(42): 1–26
- [19] 陈元媛, 高岩, 刘志敏, 杜守强. 一类特殊优化问题的光滑梯度法. 运筹学学报, 2017, 21(2): 119–125
(Chen Y Y, Gao Y, Liu Z M, Du S Q. The smoothing gradient method for a kind of special optimization problem. *Operations Research Transactions*, 2017, 21(2): 119–125)
- [20] 付卫红, 梁漠杨, 田德艳, 农斌. 基于部分支撑集的 L_1 范数稀疏重构算法. 计算机仿真, 2020, 37(2): 174–177
(Fu W H, Liang M Y, Tian D Y, Nong B. Algorithm for sparse recovery based on the L_1 norm of partial support set. *Computer Simulation*, 2020, 37(2): 174–177)
- [21] Yuan G L, Wei Z X, Wang Z X. Gradient trust region algorithm with limited memory BFGS update for non-smooth convex minimization. *Computational Optimization and Applications*, 2013, 54(1): 45–64
- [22] Liu Y W, Hu J F. A neural network for l_1 - l_2 minimization based on scaled gradient projection: application to compressed sensing. *Neurocomputing*, 2016, 173: 988–993
- [23] Yuan G L, Wei Z X, Li G Y. A modified Polak-Ribière-Polyak conjugate gradient algorithm for non-smooth convex programs. *Journal of Computational and Applied Mathematics*, 2014, 255: 86–96

- [24] Yuan G L, Meng Z H, Li Y. A modified Hestenes and Stiefel conjugate gradient algorithm for large-scale non-smooth minimizations and nonlinear equations. *Journal of Optimization Theory and Applications*, 2016, 168(1): 129–152
- [25] Woldu T G, 张海斌, 张鑫, 张芳. 一种求解非线性无约束优化问题的充分下降的共轭梯度法. *运筹学学报*, 2018, 22(3): 59–68
(Woldu T G, Zhang H B, Zhang X, Zhang F. A sufficient descent conjugate gradient method for nonlinear unconstrained optimization problems. *Operations Research Transactions*, 2018, 22(3): 59–68)
- [26] 周光明. Armijo型线搜索下一种共轭梯度法的收敛性. *工程数学学报*, 2008, 25(3): 405–410
(Zhou G M. Convergence properties of a conjugate gradient method with Armijo-type line searches. *Chinese Journal of Engineering Mathematics*, 2008, 25(3): 405–410)
- [27] Chen X J, Qi L Q, Sun D F. Global and superlinear convergence of the smoothing Newton method and its application to general box constrained variational inequalities. *Mathematics of Computation*, 1998, 67(222): 519–540
- [28] Chen X J, Zhou W J. Smoothing nonlinear conjugate gradient method for image restoration using nonsmooth nonconvex minimization. *SIAM Journal on Imaging Sciences*, 2010, 3(4): 765–790
- [29] Chen X J. Smoothing methods for nonsmooth, nonconvex minimization. *Mathematical Programming*, 2012(134): 71–99
- [30] Rockafellar R T, Wets R J-B. *Variational Analysis*. New York: Springer, 1998

A New Conjugate Gradient Method for the Optimization Problem with l_1 -norm

YANG YANXUE DU SHOUQIANG[†] LV SHICHUN

(School of Mathematics and Statistics, Qingdao University, Qingdao 266071, China)

([†]E-mail: sqdu@qdu.edu.cn)

Abstract In this paper, we consider the method for optimization problem with l_1 -norm. This kind of problem is widely used in compressed sensing and other fields. Based on the proposed smoothing function, a new conjugate gradient method to solve this optimization problem with l_1 -norm is proposed in this paper. The global convergence of the proposed method is analyzed under general conditions, and the related numerical results also show the effectiveness of it.

Keywords l_1 -norm; conjugate gradient method; global convergence

MR(2020) Subject Classification 90C30; 65K05

Chinese Library Classification 0221